

CAPÍTULO 7

Ejercicio 7.1

Suponer el siguiente modelo:

$$y_t = \beta + u_t$$

en donde β es un parámetro.

- 1). Definir el predictor óptimo para un periodo y dos periodos hacia delante suponiendo que u_t es un ruido blanco. Obtener la esperanza y varianza de los correspondientes errores de predicción.
- 2). Repetir lo indicado en 1) suponiendo ahora que u_t es un proceso de medias móviles de orden 1.
- 3). Definir una predicción por intervalo un periodo hacia delante suponiendo que u_t es un ruido blanco $N(0, 1)$.
- 4). Derivar la esperanza y varianza del predictor MCO y del error de predicción suponiendo que u_t es un ruido blanco.

Solución

- 1). El predictor óptimo para cualquier horizonte de predicción, h , viene dado por (demostrar este resultado):

$$\hat{y}_T(h) = E(y_{T+h} / I_T)$$

Aplicando esta fórmula a nuestro enunciado resulta,

$$\hat{y}_T(h) = \beta \quad \text{para todo } h.$$

El error de predicción será

$$e_T(h) = y_{T+h} - \hat{y}_T(h) = u_{T+h}$$

Las propiedades se derivan de forma inmediata.

- 2). Si $u_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$, el predictor será,

$$\hat{y}_T(h) = \beta + E(u_{T+h} / I_T)$$

En este caso, $e_T(1)$ y $e_T(2)$ no coinciden.

- 3). Por ser $e_T(1) \approx N(0, \sigma^2)$, el intervalo será

$$\beta \pm N_{\frac{\alpha}{2}} \sigma$$

- 4). El predictor MCO es

$\hat{y}_T(1) = \hat{\beta} = \bar{y}$ por lo que las propiedades del predictor serán las propiedades de la media (derivar estas propiedades). El error de predicción MCO es,

CAPÍTULO 7

Ejercicio 7.1

$$\hat{e}_T(1) = \beta + u_{T+1} - \beta - \bar{u}$$

derivandose los momentos de forma directa.

Ejercicio 7.2

Suponer que el PGD viene dado por:

$$y_t = 0.5y_{t-1} + u_t$$

en donde u_t es un ruido blanco.

- 1). Para uno y dos periodos hacia delante definir los predictores óptimos.
- 2). Definir los correspondientes errores de predicción y derivar la esperanza y varianza de estos errores.
- 3). Derivar el predictor óptimo para el periodo $T+h$ haciendo $h \rightarrow \infty$. Obtener para este caso el error de predicción, su media y su varianza.

Solución

- 1). El predictor óptimo se define como,

$$\hat{y}_T(h) = E(y_{T+h} / I_T)$$

Por ejemplo,

$$\hat{y}_T(2) = 0.5^2 y_T$$

- 2). Los errores de predicción son:

$$e_T(1) = u_{T+1}$$

$$e_T(2) = u_{T+2} + 0.5u_{T+1}$$

Las propiedades estocásticas de estos dos errores se derivan de forma inmediata.

- 3). El predictor sería

$$\hat{y}_T(h) = 0.5^h y_T \text{ y el error de predicción,}$$

$$e_T(h) = \sum_{i=0}^{\infty} 0.5^i u_{T+h-i}$$

Por lo que la esperanza del error es cero y la varianza es igual a:

$$Var(e_T(h)) = \frac{\sigma^2}{0.75}$$

CAPÍTULO 7

Ejercicio 7.3

Demostrar que el error de predicción definido a partir de un modelo econométrico puede descomponerse en cinco componentes . Interpretar cada uno de ellos e indicar como puede relativizarse la importancia de los mismos.

Solución

Puede encontrarse la solución al final del Capítulo 0.

Ejercicio 7.4

Para el modelo con un regresor:

$$y_t = \beta x_t + u_t$$

en donde u es un ruido blanco. Utilizando las observaciones muestrales, los errores de predicción MCO para $T+1$ y $T+2$ hechos en T y en $T+1$ respectivamente, son los siguientes:

$$e_T(1) = y_{T+1} - \hat{\beta}_1 x_{T+1}$$

$$e_{T+1}(1) = y_{T+2} - \hat{\beta}_2 x_{T+2}$$

en donde $\hat{\beta}_1$ es el estimador MCO utilizando información hasta T y $\hat{\beta}_2$ es el estimador con información hasta $T+1$. Se pide:

- 1). La esperanza de $e_T^2(1)$.
- 2). La varianza de $e_{T+1}^2(1)$.
- 3). Demostrar la independencia de $e_T(1)$ y $e_{T+1}(1)$.

Solución

1) y 2). Podemos escribir,

$$e_T(1) = y_{T+1} - \hat{y}_T(1) = u_{T+1} - \frac{\sum x_t u_t}{\sum x_t^2} x_{T+1}$$

Suponiendo normalidad, se tiene que,

$$e_T(1) \approx N(0, \sigma^2 (1 + \frac{x_{T+1}^2}{\sum x_t^2}))$$

A partir de los resultados anteriores se llega a:

$$\left(\frac{e_T(1)}{\sigma (1 + \frac{x_{T+1}^2}{\sum x_t^2})^{\frac{1}{2}}} \right)^2 \approx \chi^2(1)$$

CAPÍTULO 7

Ejercicio 7.4

Se puede escribir,

$$e_T(1)^2 = \sigma^2 \left(1 + \frac{x_{T+1}^2}{\sum x_t^2}\right) \chi^2(1)$$

A partir de esta expresión se puede obtener la esperanza y varianza de $e_T^2(1)$ usando $E\chi^2(1) = 1$ y $Var(\chi^2(1)) = 2$

3). Tener en cuenta que,

$$\hat{\beta}_1 = \beta + \frac{\sum x_t u_t}{\sum x_t^2}$$

$$\hat{\beta}_2 = \beta + \frac{\sum x_t u_t + x_{T+1} u_{T+1}}{\sum x_t^2 + x_{T+1}^2}$$

A partir de estas expresiones tenemos,

$$Cov(e_T(1), e_{T+1}(1)) = E(e_T(1)e_{T+1}(1)) = E\left[\left(u_{T+1} - \frac{\sum x_t u_t}{\sum x_t^2} x_{T+1}\right)\left(u_{T+2} - \frac{\sum x_t u_t + x_{T+1} u_{T+1}}{\sum x_t^2 + x_{T+1}^2} x_{T+2}\right)\right]$$

Teniendo en cuenta que las u son ruidos blancos, se tiene que

$$Cov(e_T(1), e_{T+1}(1)) = E\left[\left(\frac{\sum x_t u_t}{\sum x_t^2} x_{T+1}\right)\left(\frac{\sum x_t u_t}{\sum x_t^2 + x_{T+1}^2} x_{T+2}\right) - (u_{T+1}) \frac{x_{T+1} u_{T+1}}{\sum x_t^2 + x_{T+1}^2} x_{T+2}\right] = 0$$

Ejercicio 7.5

Suponer dos modelos:

$$M1: y_t = \beta_1 x_{1t} + u_{1t}$$

$$M2: y_t = \beta_1 x_{1t} + \beta_2 x_{2t} + u_{2t}$$

en donde u_{1t} y u_{2t} son ruidos blancos. Sean e_{p1} y e_{p2} los errores de predicción MCO de ambos modelos para un periodo extramuestral. Obtener:

- 1). Ee_{p1} y Ee_{p2} suponiendo que el PGD es M2.
- 2). Ee_{p2} suponiendo que genera los datos M1.

CAPÍTULO 7

Ejercicio 7.5

- 3). $E(e_{p1}^2 - e_{p2}^2)$ generando los datos M2.
4). $\text{Var}(e_{p1}^2)$ y $\text{Var}(e_{p2}^2)$ generando los datos M2.

Solución

1). Sea x_1 el vector de observaciones de la variable incluida en el primer modelo y sea X la matriz de observaciones de las dos variables incluidas en el segundo modelo. Tendremos,

$$e_{p1} = y_{p1} - \hat{\beta}_1 x_{p1}$$

$$Ee_{p1} = \beta_2 x_{p2} - B_{12} \beta_2 x_{p2} = h_{12p}$$

Para el segundo modelo se tiene que,

$$e_{p2} = y_p - x_p' \beta - x_p' (X' X)^{-1} X' u_2 = u_{p2} - x_p' (X' X)^{-1} X' u_2$$

por lo que,

$$Ee_{p2} = 0.$$

2). Si genera el primer modelo se tiene que

$$\hat{\beta} = \begin{pmatrix} \beta_1 \\ 0 \end{pmatrix} + (X' X)^{-1} X' u_1$$

por lo que la esperanza sigue siendo cero.

CAPÍTULO 7

Ejercicio 7.5

3). Resultado general de la Teoría Estadística. Para una distribución $\chi^2(k, \lambda^2)$, en donde k son los grados de libertad y λ^2 es el parámetro de no centralidad, se tiene que:

$$E\chi^2(k, \lambda^2) = k + \lambda^2$$

$$Var(\chi^2(k, \lambda^2)) = 2(k + 2\lambda^2)$$

Veamos como aplicar estos resultados a nuestro ejercicio; Si genera los datos el segundo modelo se tiene que,

$$e_{p1}^2 = (\sigma_2^2(1 + \frac{x_{p1}^2}{\sum x_{1t}^2}))\chi^2(1, \frac{h_{12p}^2}{\sigma_2^2(1 + \frac{x_{p1}^2}{\sum x_{1t}^2})})$$

A partir de esta expresión, los resultados que se piden para e_{p1}^2 se obtienen de forma inmediata. Para e_{p2}^2 los resultados se obtienen a partir de:

$$\frac{e_{p2}^2}{\sigma_2^2(1 + x_p'(X'X)^{-1}x_p)} \approx \chi^2(1)$$

Ejercicio 7.6

Sean A_t y P_t los valores observados y predichos. El Error Cuadrático Medio de Predicción lo definimos como:

$$ECMP = \frac{1}{T} \sum (A_t - P_t)^2$$

CAPÍTULO 7

Ejercicio 7.6

Demostrar que este estadístico puede escribirse, alternativamente, como:

$$ECM = (\bar{P} - \bar{A})^2 + (1 - R_{AP}^2) \sigma_A^2 + (1 - \hat{\beta})^2 \sigma_P^2$$

o bien como:

$$ECM = (\bar{P} - \bar{A})^2 + 2(1 - R_{AP}) \sigma_A \sigma_P + (\sigma_P - \sigma_A)^2$$

en donde \bar{A} y \bar{P} son las medias de los valores observados y predichos, respectivamente; σ_A^2 y σ_P^2 son las respectivas varianzas; R_{AP} es el coeficiente de correlación entre ambas variables y $\hat{\beta}$ es el estimador MCO de β en el modelo:

$$A_t = \alpha + \beta P_t + u_t$$

Solución

Genéricamente podemos escribir,

$$\begin{aligned} \bar{A} &= \frac{\sum A_t}{T} ; \quad \sigma_A^2 = \frac{\sum A_t^2}{T} - \bar{A}^2 \\ \sigma_{AP} &= \frac{\sum A_t P_t}{T} - \bar{A} \bar{P} ; \quad R_{AP} = \frac{\sigma_{AP}}{\sigma_A \sigma_P} ; \quad \hat{\beta} = \frac{\sigma_{AP}}{\sigma_P^2} \end{aligned}$$

El ECM puede escribirse como:

$$ECM = \frac{\sum (A_t - P_t)^2}{T} = \frac{1}{T} \sum A_t^2 + \frac{1}{T} \sum P_t^2 - \frac{2}{T} \sum A_t P_t$$

sumando y restando \bar{A}^2 , \bar{P}^2 y $2\bar{A}\bar{P}$ y agrupando términos se obtiene,

$$ECM = (\bar{A} - \bar{P})^2 + \sigma_A^2 + \sigma_P^2 - 2\sigma_{AP}$$

Al primer resultado se llega sumando y restando $\hat{\beta} \sigma_{AP}$.

Al segundo resultado se llega sumando y restando $2\sigma_A \sigma_P$

Ejercicio 7.8

Suponer que y_t está generada por un modelo ARIMA (p, d), siendo la media del modelo ARMA igual a cero. Para un horizonte temporal de pre-

dicción igual a $h = 1, 2$ y 4 periodos obtener el predictor óptimo y el correspondiente error de predicción, su media y varianza en los siguientes casos:

CAPÍTULO 7

Ejercicio 7.8

- 1). $d=1, p=0, q=0$.
- 2). $d=1, p=0, q=1$.
- 3). $d=1, p=1, q=0$.
- 4). $d=1, p=1, q=1$.

Solución

1). El proceso puede escribirse como:

$$\Delta y_t = \varepsilon_t$$

Para el horizonte h el predictor es:

$$\hat{y}_T(h) = y_T$$

y el error de predicción

$$e_T(h) = \varepsilon_{T+1} + \dots + \varepsilon_{T+h}$$

Los momentos se obtienen de forma directa.

2). El modelo puede escribirse como,

$$\Delta y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1}$$

y los predictores y errores de predicción

$$\hat{y}_T(1) = y_T - \theta_1 \varepsilon_T ; \quad e_T(1) = \varepsilon_{T+1}$$

$$\hat{y}_T(2) = \hat{y}_T(1) ; \quad e_T(2) = \varepsilon_{T+1} + \varepsilon_{T+2} - \theta_1 \varepsilon_{T+1}$$

$$\hat{y}_T(3) = \hat{y}_T(2) ; \quad e_T(3) = e_T(2) + \varepsilon_{T+3} - \theta_1 \varepsilon_{T+2}$$

y, en general:

$$\hat{y}_T(h) = \hat{y}_T(h-1) + \varepsilon_{T+h} - \theta_1 \varepsilon_{T+h-1}$$

3). El modelo es

$$\Delta y_t = \phi \Delta y_{t-1} + \varepsilon_t \quad \text{o bien} \quad y_t = (1+\phi)y_{t-1} - \phi y_{t-2} + \varepsilon_t$$

Los predictores y errores de predicción son

$$\hat{y}_T(1) = (1+\phi)y_T - \phi y_{T-1} ; \quad e_T(1) = \varepsilon_{T+1}$$

$$\hat{y}_T(2) = (1+\phi)\hat{y}_T(1) - \phi y_T ; \quad e_T(2) = (1+\phi)e_T(1) + \varepsilon_{T+2}$$

y, en general,

$$\hat{y}_T(h) = (1+\phi)\hat{y}_T(h-1) - \phi \hat{y}_T(h-2) ;$$

$$e_T(h) = (1+\phi)e_T(h-1) - \phi e_T(h-2) + \varepsilon_{T+h}$$

Los momentos se obtienen de forma directa.

4). El modelo puede escribirse como:

$$\Delta y_t = \phi \Delta y_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}$$

Para $h \geq 2$ el predictor y el error de predicción son

CAPÍTULO 7

Ejercicio 7.8

$$\begin{aligned}\hat{y}_T(h) &= (1 + \phi)\hat{y}_T(h-1) - \phi\hat{y}_T(h-2) \\ e_T(h) &= (1 + \phi)e_T(h-1) - \phi e_T(h-2) + \varepsilon_{T+h} - \theta_1 \varepsilon_{T+h-1}\end{aligned}$$

Teniendo en cuenta que,

$$\hat{y}_T(1) = (1 + \phi)y_T - \phi y_{T-1} - \theta_1 \varepsilon_T; \quad e_T(1) = \varepsilon_{T+1}.$$